

Ferramentas

- Linguagens (Python, R, MATHLAB...)
- Ambientes/Distribuições (Anaconda)
- Pacotes (pandas, scikit-learn, SciPy...)
- IDEs (spyder, R-Studio)

Linguagens/Ambientes









Full programming power

More homogeneous environment

Business Insider

What it's like to have the best job in America right now





Employees say being a data scientist is the best job in the US. Glassdoor

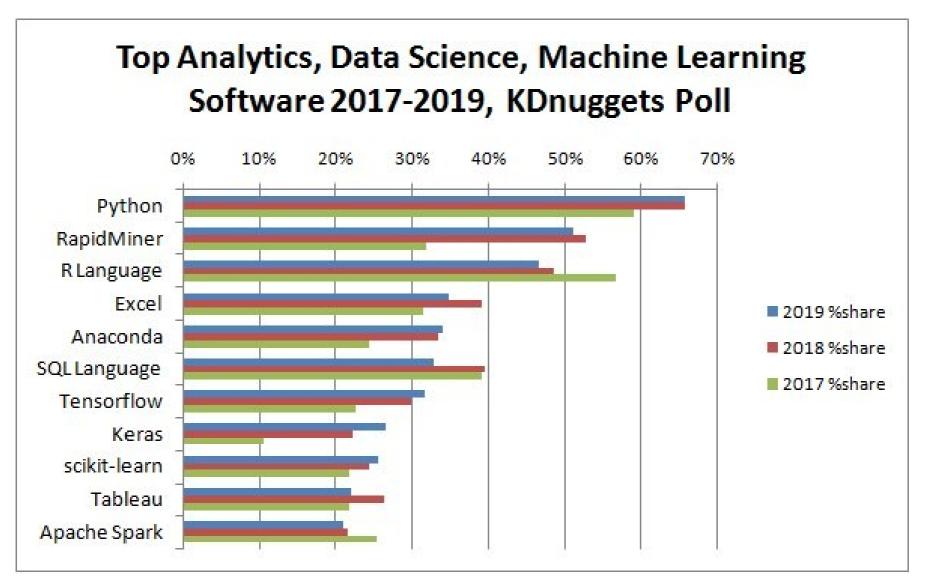
http://www.businessinsider.com/data-scientist-best-job-in-us-right-now-2018-

Business Insider - skills

- SQL
- Python/R (maybe Tableau)
- Modeling
- Dashboarding (visualization)
- More recent big data tools like Hadoop

"Just as important is having product and business sense," Cheng said. "Having your own intuition and understanding of your subject area so that you can come up with good questions and build models that actually make sense to the area that you're building."

Market Share





Programming language popularity: Python tightens its grip at the top

Python retains its top spot as the most popular language for electrical and

electronics engineers.

Rank	Language	Туре		Score
1	Python	#	₽ @	100.0
2	Java	⊕ □	D	96.3
3	С	0	₽ @	94.4
4	C++	0	₽ @	87.5
5	R		Ç	81.5
6	JavaScript	#		79.4
7	C#	⊕ □	₽ @	74.5
8	Matlab		Ģ	70.6





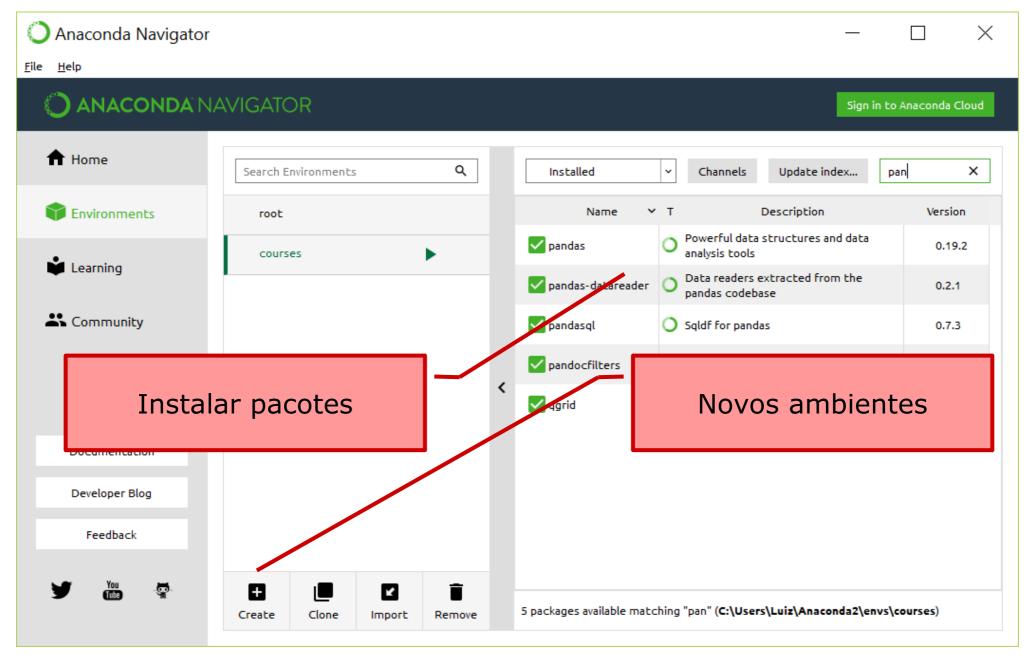
Anaconda

- Anaconda é uma distribuição open source para as linguagens Python e R. Oferece opções para processamento em larga escala, análise preditiva, computação científica, etc. com o objetivo de simplificar o gerenciamento de pacotes.
- Usa conda para gerenciamento de pacotes

Anaconda Navigator



Anaconda Navigator

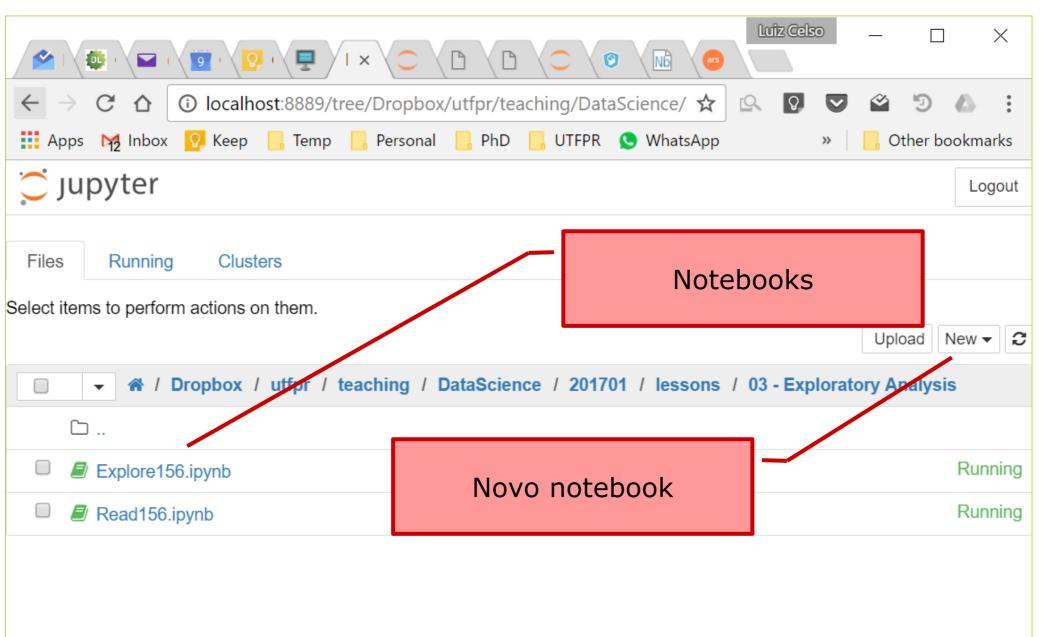




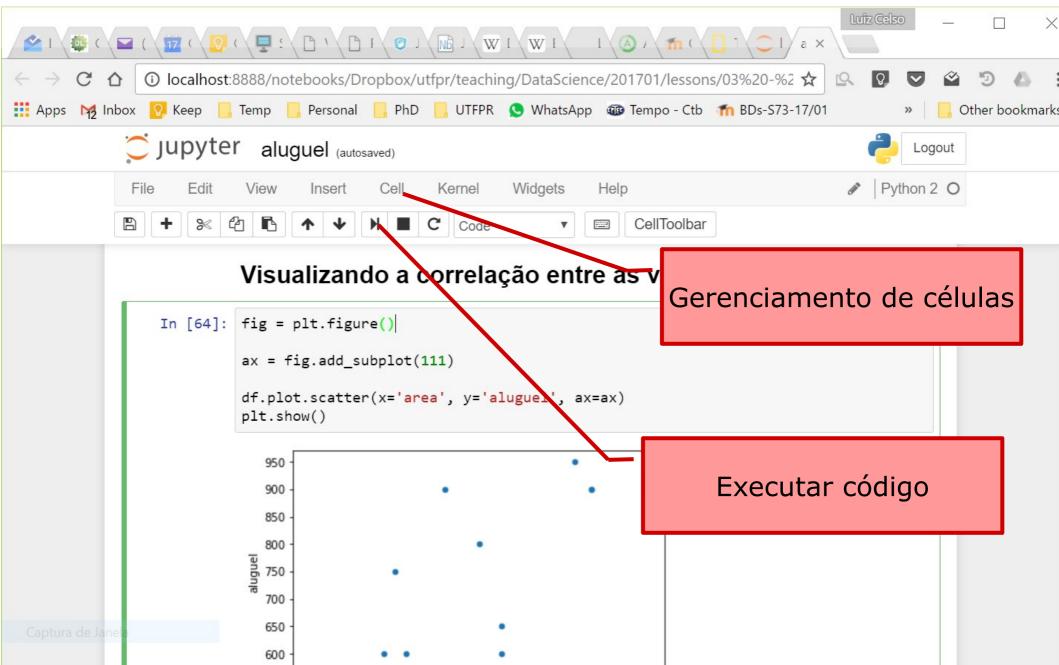
Jupyter Notebook

- É uma ferramenta que unifica a escrita de código, sua documentação e a visualização dos resultados.
- Usado para limpeza e transformação de dados Data, simulação numérica, modelagem estatística, aprendizado de máquina, etc.
- Inicialmente focado em Python, mas já suporta mais de 40 linguagens como R, Julia e Scala.

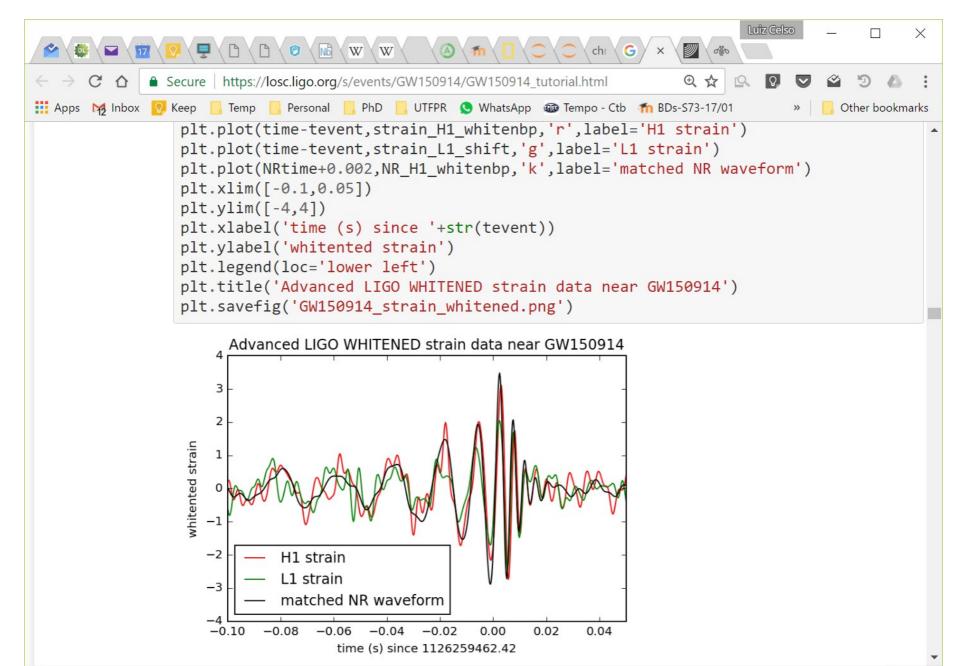
Jupyter Notebook



Jupyter Notebook



LIGO + Jupyter



Documentação/Código

Formatação

É possivel formatar a célula de documentação de diversas formas. Para ver como esta célula que você está lendo foi formatada, clique duas vezes para iniciar a edição. A linguagem usada para fazer a formatação é chamada *Markdown*. Ela permite diversas coisas como:

- Listas
- Itálico
- Negrito
- Fórmulas matemáticas: $f(x) = x^2 + 2x + log_2 x$
- Links: UTFPR

Para conhecer outras possibilidades de uso de Markdown, clique em Help->Markdown no menu acima.

Claro, o Jupyter permite códigos e visualizações mais complexas como no exemplo abaixo. Execute a célula para ver o resultado.

Documentação - Markdown

Formatação

É possivel formatar a célula de documentação de diversas formas. Para ver como esta célula que você está lendo foi formatada, clique duas vezes para iniciar a edição. A linguagem usada para fazer a formatação é chamada *Markdown*. Ela permite diversas coisas como:

- Listas
- *Itálico*
- **Negrito**
- Fórmulas matemáticas: \$f(x)=x²+2x+log 2x\$
- Links: [UTFPR](http://www.utfpr.edu.br)

Para conhecer outras possibilidades de uso de *Markdown*, clique em `Help->Markdown` no menu acima.

Exercícios!

- Revise o conteúdo e faça os exercícios do notebook
 01a-Jupyter Notebook_Introdução.ipynb
- Link: https://gitlab.com/luizcelso/datascience
- Use o Binder clicando no link:



Exercícios!

Execute o notebook anterior localmente:

```
git clone https://gitlab.com/luizcelso/datascience.git
cd datascience/
jupyter-notebook
```

Pacotes Python

- Pandas operações de manipulação de dados estruturados
- NumPy estruturas e operações numéricas
- Scikit Learn machine learning
- Matplotlib plotagem de gráficos
- Veremos também: StatsModels, NetworkX, NLTK, SeaBorn, Bokeh...

Instalação de Pacotes

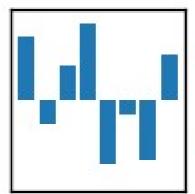
- Recomendado: Use o Anaconda Navigator
- Pela linha de comando: conda install <pacote> ou pip install <pacote>
- Instalar sem privilégios de administrador: pip install --user <pacote>

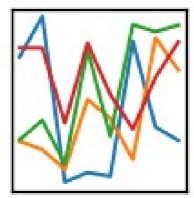
Instalação - Exemplo

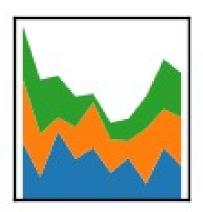
Aqui no Laboratório:
 pip install --user pandas matplotlib

pandas

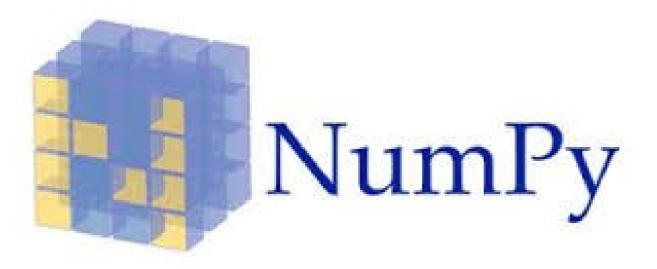
$$y_{it} = \beta' x_{it} + \mu_i + \epsilon_{it}$$







- Used for structured data operations and manipulations. It is extensively used for data munging and preparation.
- Have been instrumental in boosting Python's usage in data scientist community.



- The most powerful feature of NumPy is ndimensional array.
- This library also contains basic linear algebra functions, Fourier transforms, advanced random number capabilities and tools for integration with other low level languages like Fortran, C and C++
- Efficient processing



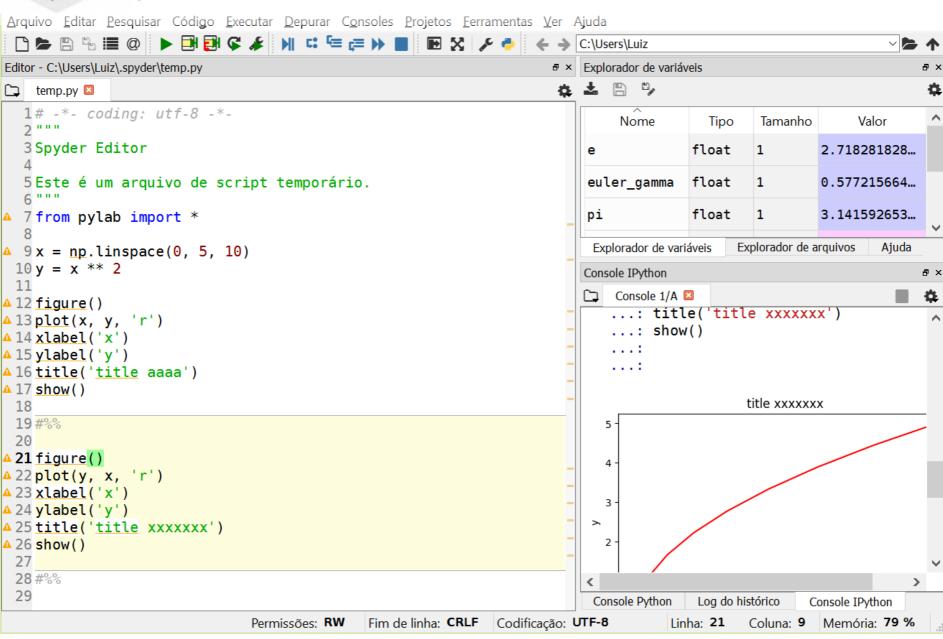
- Scikit-learn is a free software machine learning library for the Python programming language
- Features various classification, regression and clustering algorithms including support vector machines, random forests, gradient boosting, kmeans and DBSCAN
- Designed to interoperate with NumPy and SciPy



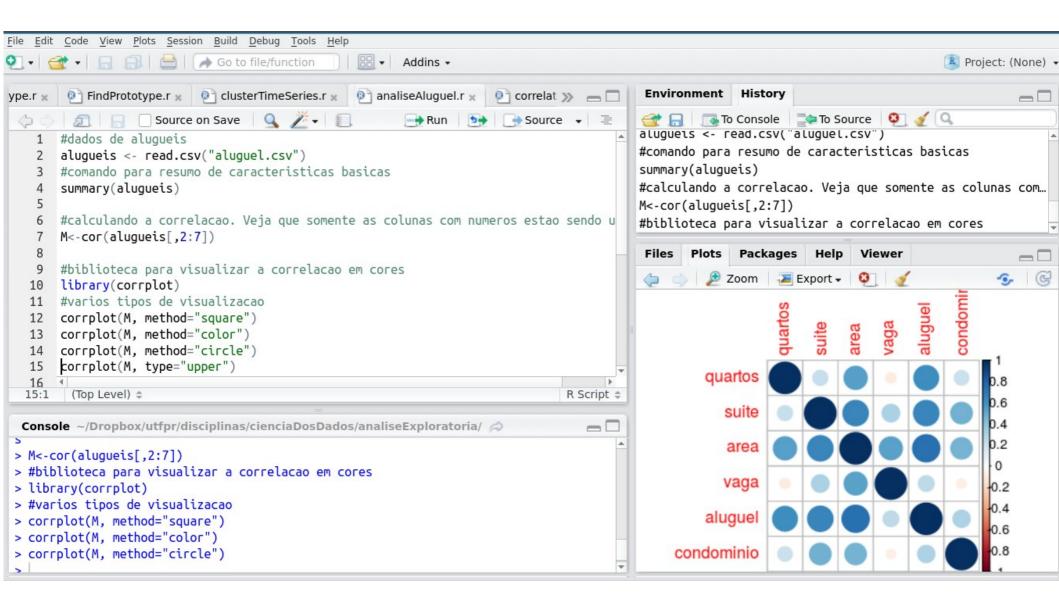
- For plotting vast variety of graphs, starting from histograms to line plots to heat plots..
- You can use Pylab feature in Jupyter notebook (ipython notebook –pylab = inline) to use these plotting features inline.
- Alternatives: Bokeh, Seaborn



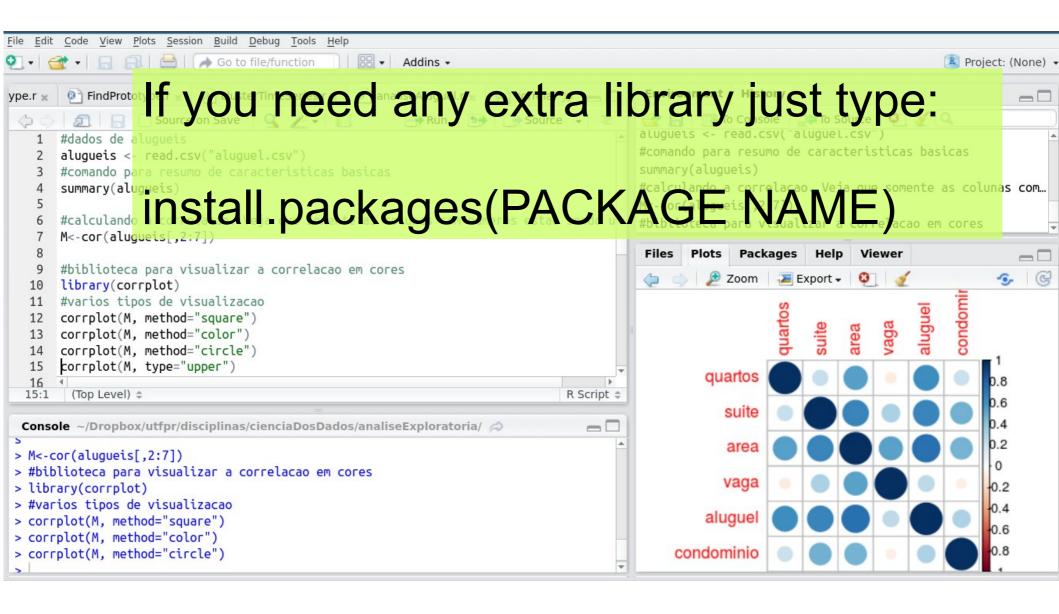
spyder Data Science IDE



R Studio



R Studio



BI Tools



